

Challenge C4D：本地大模型 Agent 技能（Local LLM Agent Skills with Gemma 4）

🔥 C4 的硬核分支——不依赖云端 API，在你自己的电脑上跑大模型，驱动 Agent 技能。本质：证明你能在本地设备上运行一个有真实能力的 LLM Agent——不花一分钱 API 费用。

⚠️ 核心挑战：在你自己的设备上运行 Agent

Google 刚刚发布了 **Gemma 4**——四款开源模型，Apache 2.0 协议，专为本地运行和 Agent workflow 设计。

你的任务：

1. 在你的电脑/手机上下载并运行 Gemma 4 模型
2. 用本地模型驱动 **Agent 技能**——执行函数调用、生成结构化输出、完成多步任务
3. 生成一个交互式地图——展示 SIAS University（郑州西亚斯学院）或其他有意义的地点
4. 截图/录屏发群里证明是在本地跑的

💡 为什么要本地跑？因为**数据主权**和**零成本推理**是 AI 工程师的核心能力。云端 API 会断、会涨价、会审查——但你本地的模型永远属于你。

📊 Gemma 4 家族：四款模型，你跑哪个？

Gemma 4 有四款模型，你必须在提交中明确标注你跑的是哪一款：

模型	参数量	活跃参数	最低内存 (4-bit)	上下文长度	适合设备
Gemma 4 E2B	~2B effective	2B	~5 GB	128K	手机、树莓派、老旧笔记本
Gemma 4 E4B	~4.5B effective	4.5B	~5 GB	128K	普通笔记本（推荐入门）
Gemma 4 26B		3.8B			16GB+ 显存 GPU 或

MoE	26B total	active	~18 GB	256K	24GB+ Mac
Gemma 4 31B Dense	31B	31B	~20 GB	256K	24GB+ 显存 GPU 或 32GB+ Mac


⚠️ 你必须标注你用的是哪个模型 + 什么量化方式（如 Q4_K_M）+ 在什么设备上跑的。这是评审的关键信息。

所有四款模型都支持：多模态（文本+图像）、原生函数调用（function calling）、系统提示、结构化 JSON 输出、Agent 工作流。

🎯 你要做什么

核心任务：本地 Agent + 交互式地图

在你的设备上用 Gemma 4 完成以下流程：



地图要求：

- 必须包含 **SIAS University（郑州西亚斯学院）** 或你选择的其他有意义的地点
- 必须是**交互式的**（可缩放、可点击标记）
- 标记点必须包含有意义的信息（地点名称、描述、坐标）
- 地点数据必须由**本地 Gemma 4 模型生成**（不是你手写的 JSON）

Agent 技能要求：

- 模型必须通过**函数调用（function calling）或结构化输出**来生成地图数据
- 必须展示至少一个 Agent 能力：工具调用、多步推理、代码生成、或数据结构化

运行 Gemma 4 的方式

方案	难度	说明
Ollama (推荐)	★	一行命令跑起来，自带 OpenAI 兼容 API
LM Studio	★	GUI 界面，拖拽下载模型，适合非 CS 专业
llama.cpp	★★	最底层，性能最优，需要编译
Unsloth Studio	★★	网页 UI，支持微调
AI Edge Gallery	★★	Google 官方手机端运行方案

快速开始 (Ollama)

```
# 1. 安装 Ollama
curl -fsSL https://ollama.com/install.sh | sh # Linux/Mac
# Windows: 从 ollama.com 下载安装包

# 2. 下载 Gemma 4 (选一个适合你设备的)
ollama run gemma4:e2b # 最小，手机/老电脑都能跑
ollama run gemma4:e4b # 推荐入门，普通笔记本
ollama run gemma4:26b # MoE，需要 16GB+ 内存
ollama run gemma4:31b # 最强，需要 24GB+ 内存

# 3. 验证 function calling
curl http://localhost:11434/v1/chat/completions \
  -H "Content-Type: application/json" \
  -d '{
    "model": "gemma4",
    "messages": [{"role": "user", "content": "List 5 landmarks near SIAS Universi
  }'
```

生成交互式地图的方式

方案	语言	说明
Folium	Python	<code>pip install folium</code> ，最简单的交互式地图
Leaflet.js	HTML/JS	纯前端，生成 HTML 文件直接打开

Plotly	Python	支持 Mapbox, 更花哨
Deck.gl	JS	3D 地图可视化

最简示例 (Python + Ollama + Folium)

```
import requests, json, folium

# 1. 用本地 Gemma 4 生成地点数据
response = requests.post("http://localhost:11434/v1/chat/completions", json={
    "model": "gemma4",
    "messages": [
        {"role": "system", "content": "You are a geography assistant. Always resp"},
        {"role": "user", "content": "\"\"List 8 notable locations at or near SIAS U
        in Xinzheng, Henan, China. Return JSON array with fields:
        name, name_zh, latitude, longitude, description\"\""}
    ]
})

# 2. 解析模型输出
data = json.loads(response.json()["choices"][0]["message"]["content"])

# 3. 生成交互式地图
m = folium.Map(location=[34.40, 113.73], zoom_start=14)
for loc in data:
    folium.Marker(
        [loc["latitude"], loc["longitude"]],
        popup=f"<b>{loc['name_zh']}</b><br>{loc['description']}",
        tooltip=loc["name"]
    ).add_to(m)
m.save("sias_map.html")
print("地图已生成: sias_map.html")
```

四级任务

Level 1: 本地跑通 Gemma 4 (Bronze 🏅)

在你的设备上成功运行 Gemma 4 并完成基本对话。

- 安装 Ollama 或 LM Studio
- 下载任意一款 Gemma 4 模型

- 成功运行并截图证明（包含模型名称、设备信息）
- 让模型生成一段关于 SIAS University 的介绍文字

交付： 运行截图 + 设备信息 + 模型版本

Level 2: Agent 函数调用 + 交互式地图 (Silver 🥈)

用本地 Gemma 4 的 Agent 能力生成交互式地图。

- 通过 Ollama API 或 function calling 让模型生成结构化地点数据
- 用 Folium / Leaflet.js 渲染交互式地图
- 地图包含 SIAS University 及周边至少 5 个标记点
- 每个标记点有名称、描述、坐标

交付： 交互式地图 HTML + 生成地图的完整代码 + 模型输出日志

Level 3: 完整 Agent 技能包 (Gold 🥇)

构建一个可复用的本地 Agent 技能，不仅仅是地图。

在 Level 2 基础上，展示更深层的 Agent 能力：

扩展方向	说明
多轮对话 Agent	用户可以交互式地添加/修改地图标记
多工具调用	模型调用多个函数（查天气、查路线、查评分等）
代码生成 Agent	模型自动生成 Python/JS 代码并执行
视觉理解	给模型一张校园照片，让它识别并标注在地图上
多语言地图	中英文双语标注 + 多语言描述

交付： 完整技能包（可打包为 .skill 或 GitHub repo）+ 演示录屏

Level 4: 极限优化 + 设备适配 (Platinum 💎)

把本地 Agent 推到极限——不同设备、不同模型、极致优化。

在 Level 3 基础上，选择至少两项：

- **模型对比报告**：E2B vs E4B vs 26B vs 31B 在 Agent 任务上的表现对比（速度、质量、内存）
- **设备适配**：在手机（AI Edge Gallery）、笔记本、台式机上分别跑通
-  **Uncensored 模型（加分）**：运行一个无审查版本（如社区微调的 uncensored 变体），对比默认模型在 Agent 任务上的差异
- **量化对比**：同一模型不同量化级别（Q4 vs Q8 vs FP16）的质量/速度权衡
- **性能调优**：context length、batch size、GPU offload 等参数调优文档

交付：完整技术报告 + 多设备/多模型对比数据 + GitHub repo

特别激励：非计算机专业优先

 首个完成 Level 2 的非计算机专业同学，直接获得 C4 最高评级。

C4D 的意义不仅是技术挑战——它证明任何专业的学生都能掌握本地 AI 部署。无论你是金融、设计、教育还是医学专业，你都应该能在自己的设备上运行 AI。

非 CS 同学推荐路径：

1. 安装 **LM Studio**（图形界面，零命令行）
2. 搜索下载 **Gemma 4 E4B**（最适合笔记本）
3. 用 LM Studio 内置聊天生成地点 JSON
4. 复制粘贴到简单的 Python 脚本生成地图

需要提交什么

- | | |
|----------------------------|------------------------------|
| 姓名_C4D_方案设计.md | ← 架构、设备信息、选了哪个 Gemma 4 模型及原因 |
| 姓名_C4D_agent-skill/ | ← 你的 Agent 技能代码（或源码 zip） |
| 姓名_C4D_map.html | ← 生成的交互式地图 |
| 姓名_C4D_output_screenshots/ | ← 运行截图（必须包含模型名称+设备信息） |
| 姓名_C4D_验证报告.md | ← 模型输出质量评估 + 设备性能数据 |
| 姓名_C4D_教学说明.md | ← 怎么安装、怎么复现 |
| 姓名_C4D_AI日志.md（必须） | ← AI 使用全过程。无此项无法评审。 |
| 姓名_C4D_拿来说明.md | ← 用了哪些库/工具、参考了什么 |

 **截图/录屏中必须清晰显示以下信息：**

- 1. 运行的 Gemma 4 模型名称及版本（如 `gemma4:26b-a4b-q4_K_M`）
- 2. 运行工具（如 Ollama v0.20.2）
- 3. 设备信息（CPU/GPU、内存、操作系统）
- 4. 模型实际运行中的推理速度（tok/s）

评审标准

维度	权重	说明
本地运行验证	25%	确实在本地产起来了？截图/录屏是否充分证明？
Agent 能力展示	25%	函数调用、结构化输出、多步推理——展示了多少 Agent 能力？
地图质量	20%	交互性、标记点数量与质量、视觉效果
完成级别	15%	Level 1–4 到哪一级？
可复用性	15%	别人照着你的教学说明能跑通吗？

起步指南

Step 1: 确认你的设备能跑什么（Day 1）

查看你的设备配置：

你的设备	推荐模型	运行方式
8GB 内存笔记本	Gemma 4 E2B	Ollama / LM Studio
16GB 内存笔记本	Gemma 4 E4B	Ollama / LM Studio
16GB 显存 GPU（如 RTX 4080）	Gemma 4 26B MoE	Ollama
24GB+ Mac / 24GB 显存 GPU	Gemma 4 31B Dense	Ollama
Android/iOS 手机	Gemma 4 E2B/E4B	AI Edge Gallery

Step 2: 安装 + 下载模型 (Day 1)

```
# 方案 A: Ollama (推荐)
curl -fsSL https://ollama.com/install.sh | sh
ollama run gemma4:e4b # 或你选择的版本

# 方案 B: LM Studio (图形界面)
# 从 lmstudio.ai 下载, 搜索 Gemma 4, 一键下载
```

Step 3: 验证 Agent 能力 (Day 2–3)

测试函数调用和结构化输出:

```
# 测试结构化 JSON 输出
curl http://localhost:11434/v1/chat/completions \
  -H "Content-Type: application/json" \
  -d '{
    "model": "gemma4",
    "messages": [
      {"role": "system", "content": "Always respond in valid JSON only."},
      {"role": "user", "content": "List 3 landmarks near SIAS University with nam
    ]
  }'
```

Step 4: 生成交互式地图 (Day 3–5)

用模型输出的数据生成 Folium / Leaflet 地图。

Step 5: 打包提交 (Day 6–7)

截图、录屏、写文档、提交。

参考资源

资源	说明
Ollama Gemma 4 页面	官方 Ollama 模型页, 含所有变体
Gemma 4 官方博客	Google 发布文章, 介绍四款模型
Unsloth Gemma 4 本地运行指南	详细硬件需求 + llama.cpp 设置
Gemma 4 硬件选购指南	各模型 VRAM 需求对比

LM Studio	图形界面本地模型运行器
AI Edge Gallery	Google 官方手机端运行方案
Folium 文档	Python 交互式地图库
Leaflet.js	最流行的 JS 交互式地图库



加分项：Uncensored 模型

Gemma 4 默认模型有内容安全过滤。社区已经开始发布去审查微调版本（uncensored variants）。

如果你能：

1. 找到并运行一个 Gemma 4 uncensored 变体
2. 对比默认模型与 uncensored 模型在相同 Agent 任务上的表现差异
3. 写一份对比报告（输出质量、拒绝率、任务完成率）

——这将作为**显著加分项**。



Uncensored 不意味着有害。它意味着模型不会无理由拒绝正常请求（如生成特定地区的历史信息、讨论敏感但合法的学术话题）。你需要在报告中负责任地讨论这个话题。

为什么 C4D 值得做

- C4 = 我会做一个技能
- C4A = 我会评审所有人的技能
- C4B = 我会做内容发布流水线
- C4C = 我会做端到端自动化系统
- C4D = 我能在自己的设备上运行 AI Agent——不依赖任何云服务

C4D 训练的是**AI 自主权**——

- **隐私**：你的数据不离开你的设备
- **成本**：零 API 费用，无限推理
- **自由**：不受平台审查和服务中断影响
- **理解**：你真正理解模型是怎么跑起来的，不是黑盒调 API

想象一下：你在飞机上、在没有网络的教室里、在任何地方——打开笔记本电脑，本地模型立刻可用。这就是 **AI 数字主权**。

C4D 的终极价值：

云端 AI 是租来的能力。本地 AI 是你拥有的能力。C4D 证明你不仅会 *使用* AI，你还会 *部署* AI。一台笔记本 + 一个开源模型 + 你的工程能力 = 完全自主的 AI Agent。🏆 **首个完成的非计算机专业同学，直接获得 C4 最高评级。**